Федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский университет ИТМО»

Учебно-исследовательская работа №1 по дисциплине Моделирование
Статистический анализ результатов измерений

Выполнил: Снагин Станислав Максимович
Проверил: Авксентьева Елена Юрьевна
Поток: 2.3

Санкт-Петербург 2026 г.

Содержание

Задание 3
Ход работы 5
Цель работы 5
Задачи 5
Расчёт характеристик исходной последовательности 5
Промежуточные выводы 6
Анализ характера исходной последовательности 8
Промежуточные выводы 8
Корреляционный анализ 9
Промежуточные выводы 9
Гистограмма распределения частот 10
Промежуточные выводы 11
Выбор и расчёт параметров аппроксимирующего закона 12
Реализация генератора гиперэкспоненциального распределения 13
Промежуточные выводы 13
Исследование сгенерированной последовательности 14
Промежуточные выводы 17
Итоговое сравнение последовательностей 18
Промежуточные выводы 20
Вывод 21

Задание

Вариант: 29

Выполнить обработку заданной числовой последовательности для случаев, когда путём измерений получено 10, 20, 50, 100, 200 и 300 значений случайной величины. Для каждого объёма выборки необходимо:

- рассчитать оценку математического ожидания;
- рассчитать оценку дисперсии;
- определить среднеквадратическое отклонение;
- определить коэффициент вариации;
- найти доверительные интервалы для оценки математического ожидания с доверительными вероятностями 0,9, 0,95 и 0,99;
- рассчитать относительные отклонения полученных значений от результатов для выборки из 300 величин.

Результаты расчётов представить в виде таблицы и сформулировать вывод об изменении оценок при увеличении объёма выборки.

Построить график всех 300 значений исходной последовательности. По виду графика определить, является ли последовательность возрастающей, убывающей или периодической; при наличии периодичности оценить её период.

Выполнить автокорреляционный анализ исходной последовательности для сдвигов от 1 до 10. Результаты представить в числовом и графическом виде и сделать вывод о том, можно ли считать последовательность случайной.

Построить интервальный ряд и гистограмму распределения частот исходной числовой последовательности. По виду гистограммы охарактеризовать форму распределения значений.

Выполнить аппроксимацию закона распределения исходной последовательности по двум начальным моментам. Выбрать вид распределения по коэффициенту вариации и рассчитать параметры выбранного закона.

Реализовать программный генератор случайных величин в соответствии с полученным аппроксимирующим законом и сформировать последовательность из 300 значений.

Для сгенерированной последовательности повторить расчёт числовых характеристик, построить график значений и гистограмму с теоретической плотностью, а также выполнить автокорреляционный анализ. Результаты сравнить с одноимёнными характеристиками исходной последовательности.

Выполнить итоговое сравнение исходной и сгенерированной последовательностей: сопоставить их гистограммы, плотность распределения и автокорреляционные функции, заполнить форму 3, вычислить коэффициент корреляции Пирсона и оценить качество построенной модели.

Ход работы

Цель работы

Изучение методов обработки и статистического анализа результатов измерений на примере заданной числовой последовательности путём оценки её числовых характеристик при различных объёмах выборки.

Задачи

Для первых 10, 20, 50, 100, 200 и 300 значений исходной последовательности необходимо рассчитать математическое ожидание, дисперсию, среднеквадратическое отклонение, коэффициент вариации и доверительные интервалы для математического ожидания. Полученные оценки требуется сравнить с результатами для полной выборки из 300 значений.

Расчёт характеристик исходной последовательности

Для выборки объёма n оценка математического ожидания:

$$\tilde{m} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Эта оценка является состоятельной и несмещённой, а её дисперсия уменьшается обратно пропорционально объёму выборки:

$$\tilde{m} \to m \quad \text{при} \quad n \to \infty$$

$$M[\tilde{m}] = \frac{\sum_{i=1}^{N} \tilde{m}_i}{N} = m$$

$$D[\tilde{m}] = \frac{D}{n}$$

Оценка дисперсии с делением на n:

$$D^* = \frac{\sum_{i=1}^{n} (X_i - \tilde{m})^2}{n}$$

Несмещённая оценка дисперсии:

$$\tilde{D} = \frac{\sum_{i=1}^{n} (X_i - \tilde{m})^2}{n-1}$$

Среднеквадратическое отклонение и коэффициент вариации:

$$\tilde{\sigma} = \sqrt{\tilde{D}}, \quad v = \frac{\tilde{\sigma}}{|\tilde{m}|}$$

Доверительный интервал для математического ожидания с доверительной вероятностью p задаётся выражением:

$$\Pr(\tilde{m} - \varepsilon < m < \tilde{m} + \varepsilon) = p$$

$$\left(\tilde{m} - \varepsilon_p; \tilde{m} + \varepsilon_p\right)$$

Нижняя и верхняя границы доверительного интервала:

$$m_{\text{н}} = \tilde{m} - \varepsilon_p, \quad m_{\text{в}} = \tilde{m} + \varepsilon_p$$

Полуширина интервала и среднеквадратическое отклонение оценки математического ожидания вычисляются по формулам:

$$\varepsilon_p = t_p \tilde{\sigma}_{\tilde{m}}, \quad \tilde{\sigma}_{\tilde{m}} = \sqrt{\frac{\tilde{D}}{n}}$$

В соответствии с методическими материалами при $p = 0,9$ принято $t_p = 1,643$, при $p = 0,95$ - $t_p = 1,960$, при $p = 0,99$ - $t_p = 2,576$. Относительная погрешность доверительного интервала определяется как:

$$\delta = \frac{\varepsilon_p}{\tilde{m}} \cdot 100\ \%$$

В таблице 1 приведены результаты расчётов.

Характеристика		10	20	50	100	200	300
Мат. ожидание	Знач.	15,038	16,579	19,886	21,972	18,153	19,626
	%	23,38	15,53	1,33	11,95	7,51	0,00
Дов. инт. 0,9	Знач.	±8,698	±10,338	±7,254	±6,140	±3,457	±3,157
	%	175,47	227,42	129,74	94,46	9,47	0,00
Дов. инт. 0,95	Знач.	±10,376	±12,333	±8,653	±7,325	±4,124	±3,767
	%	175,47	227,42	129,74	94,46	9,47	0,00
Дов. инт. 0,99	Знач.	±13,637	±16,209	±11,373	±9,627	±5,420	±4,951
	%	175,47	227,42	129,74	94,46	9,47	0,00
Дисперсия	Знач.	280,252	791,841	974,620	1396,587	885,238	1107,975
	%	74,71	28,53	12,04	26,05	20,10	0,00
С.к.о.	Знач.	16,741	28,140	31,219	37,371	29,753	33,286
	%	49,71	15,46	6,21	12,27	10,61	0,00
К-т вариации	Знач.	1,113	1,697	1,570	1,701	1,639	1,696
	%	34,36	0,08	7,44	0,29	3,36	0,00

Таблица 1. Характеристики заданной числовой последовательности (вариант 29)

Примечание. Относительные отклонения рассчитаны от одноимённых значений для выборки объёма 300, поэтому в последнем столбце они равны нулю, не получилось объединить ячейки.

Промежуточные выводы

При увеличении объёма выборки оценки математического ожидания, дисперсии и среднеквадратического отклонения изменяются немонотонно. Для полной выборки математическое ожидание равно 19,626, дисперсия - 1107,975, а среднеквадратическое отклонение - 33,286.

Полуширина доверительного интервала с вероятностью 0,95 уменьшается с 12,333 при $n = 20$ до 3,767 при $n = 300$, поэтому оценка математического ожидания на большой выборке становится точнее.

Коэффициент вариации полной выборки равен 1,696. Значение больше единицы указывает на большой разброс исходных данных относительно среднего значения.

Анализ характера исходной последовательности

Для определения характера исходной последовательности построен график всех 300 значений в порядке их следования.

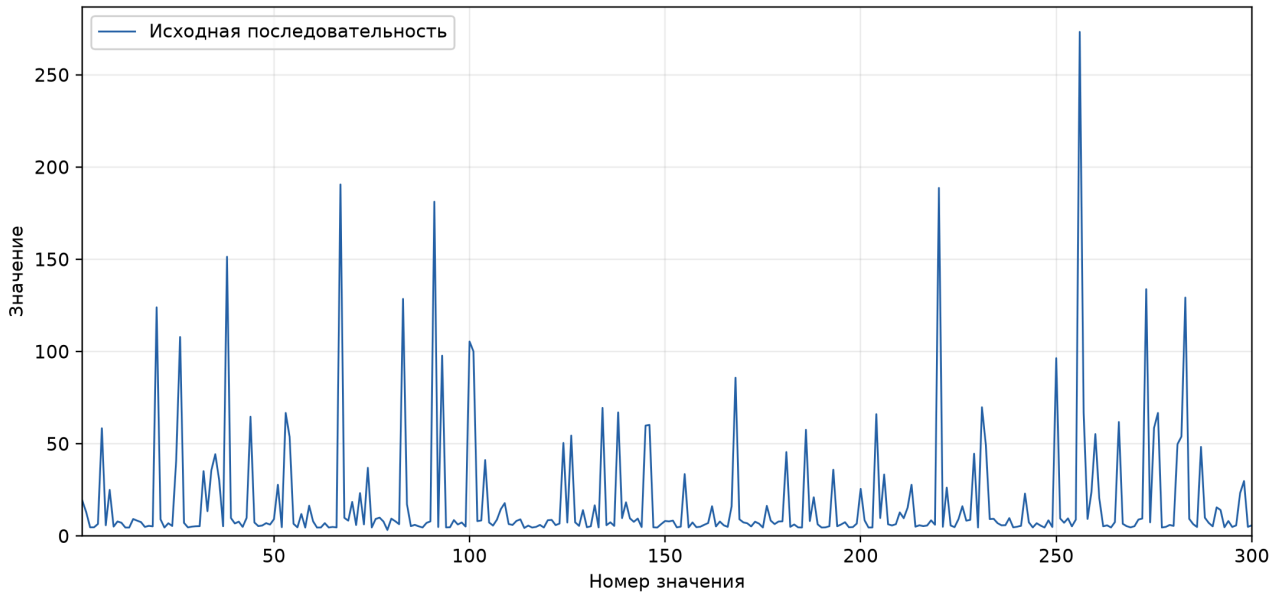


Рисунок 1. График значений исходной числовой последовательности

Промежуточные выводы

Последовательность не является ни возрастающей, ни убывающей: малые значения чередуются с отдельными резкими выбросами. Повторяющийся рисунок колебаний на графике отсутствует, поэтому явная периодичность и её период на данном этапе не обнаружены.

Корреляционный анализ

Коэффициент корреляции двух числовых последовательностей X и Y:

$$r_{XY} = \frac{\operatorname{cov}_{XY}}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^{n}(x_i - M[X])(y_i - M[Y])}{\sqrt{\sum_{i=1}^{n}(x_i - M[X])^2 \sum_{i=1}^{n}(y_i - M[Y])^2}}$$

Для автокорреляционного анализа в качестве второй последовательности используется исходная последовательность, сдвинутая на k позиций:

$$r_{XX_k} = \frac{\operatorname{cov}_{XX_k}}{\sigma_X \sigma_{X_k}} = \frac{\sum_{i=1}^{n}(x_i - M[X])(x_{i+k} - M[X_k])}{\sqrt{\sum_{i=1}^{n}(x_i - M[X])^2 \sum_{i=1}^{n}(x_{i+k} - M[X_k])^2}}$$

При $n \gg k$, где $k = 1, 2, ...$:

$$r_{XX_k} \approx \frac{\operatorname{cov}_{XX_k}}{\sigma_X^2} \approx \frac{\sum_{i=1}^{n}(x_i - M[X])(x_{i+k} - M[X])}{\sum_{i=1}^{n}(x_i - M[X])^2}$$

Коэффициенты рассчитаны для сдвигов от 1 до 10 и представлены в таблице 2.

Сдвиг ЧП	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**
К-т АК	0,0169	−0,0064	−0,0610	−0,0580	−0,0760	0,0514	0,0120	0,0280	0,0269	0,0951

Таблица 2. Результаты автокорреляционного анализа

При $n = 300$ граница по модулю равна 0,1132.

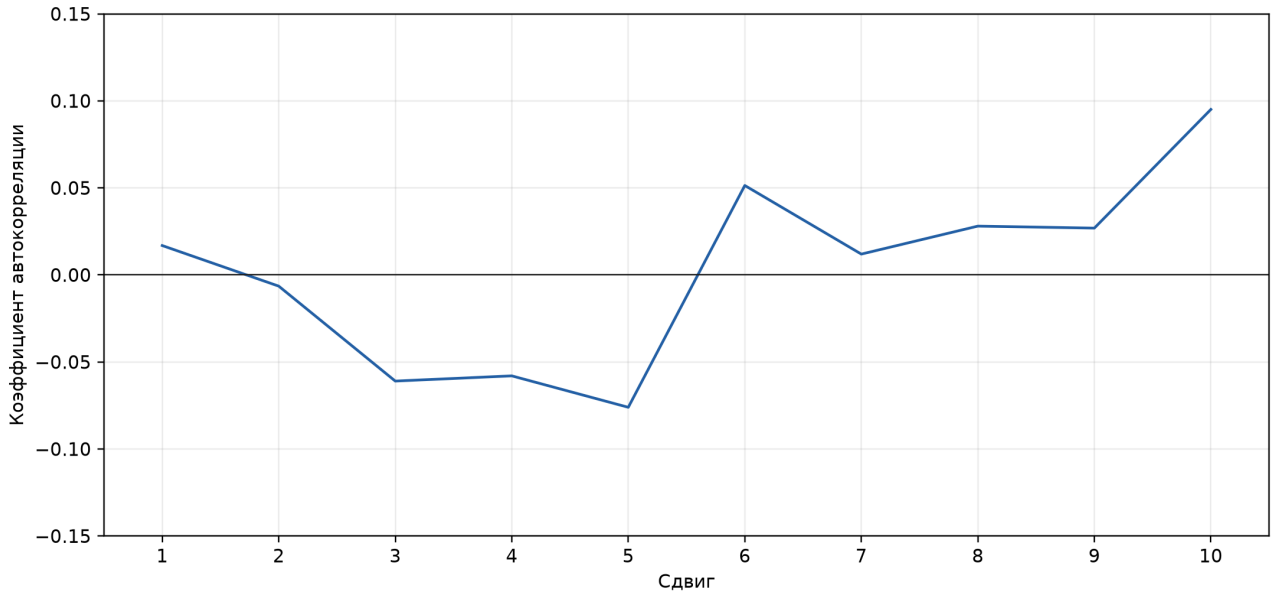


Рисунок 2. Автокорреляция исходной числовой последовательности

Промежуточные выводы

Все коэффициенты автокорреляции для сдвигов от 1 до 10 находятся внутри границ $\pm 0,1132$. Максимальный по модулю коэффициент получен при сдвиге 10 и равен 0,0951. Статистически заметной линейной зависимости между соседними и разнесёнными элементами на исследованных сдвигах не обнаружено. Поэтому исходную последовательность можно считать случайной; признаки периодичности также отсутствуют.

Гистограмма распределения частот

Ширина интервала рассчитывается по формуле:

$$h = \frac{x_{\max} - x_{\min}}{m} = \frac{273,304 - 3,290}{18} = 15,0008$$

$$m = \lceil \sqrt{n} \rceil = \lceil \sqrt{300} \rceil = 18$$

Границы интервалов и абсолютные частоты приведены в таблице 3. Последний интервал включает правую границу.

№	Левая граница	Правая граница	Частота
1	3,290	18,291	237
2	18,291	33,292	15
3	33,292	48,292	11
4	48,292	63,293	14
5	63,293	78,294	8
6	78,294	93,295	1
7	93,295	108,295	5
8	108,295	123,296	0
9	123,296	138,297	4
10	138,297	153,298	1
11	153,298	168,299	0
12	168,299	183,299	1
13	183,299	198,300	2
14	198,300	213,301	0
15	213,301	228,302	0
16	228,302	243,302	0
17	243,302	258,303	0
18	258,303	273,304	1

Таблица 3. Границы интервалов и частоты значений исходной ЧП

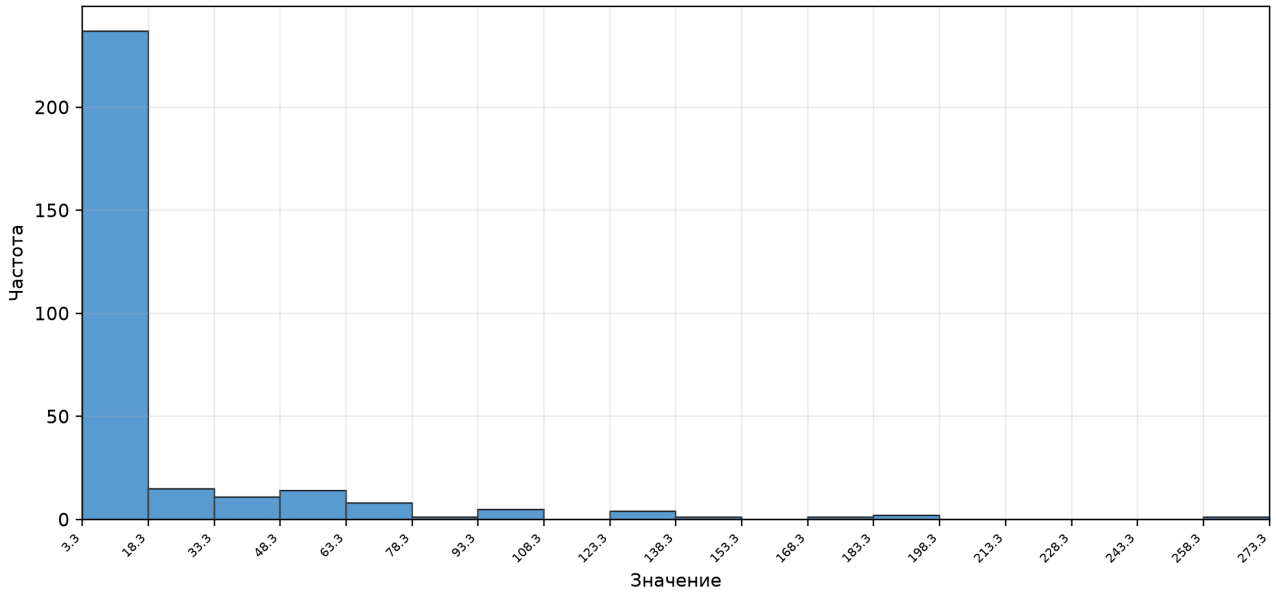


Рисунок 3. Гистограмма распределения частот исходной ЧП

Промежуточные выводы

В первом интервале от 3,290 до 18,291 находится 237 наблюдений, то есть 79% всей выборки. В первых пяти интервалах сосредоточено 285 значений, или 95% выборки. При увеличении значений частоты быстро уменьшаются, при этом встречаются отдельные наблюдения вплоть до 273,304. Следовательно, распределение имеет выраженную асимметрию и длинный правый хвост.

Выбор и расчёт параметров аппроксимирующего закона

Для исходной последовательности коэффициент вариации равен $\nu = 1,693186$, то есть он больше единицы. Поэтому для аппроксимации выбрано двухфазное гиперэкспоненциальное распределение H_2. Такой выбор согласуется с гистограммой: большинство значений мало, но встречаются редкие крупные значения, образующие длинный правый хвост.

Представим случайную величину как смесь двух экспоненциальных фаз:

$$X = \begin{cases} Y_1 & \text{с вероятностью } \ q \\ Y_2 & \text{с вероятностью } \ 1-q \end{cases}$$

Здесь Y_1 и Y_2 – экспоненциальные случайные величины со средними t_1 и t_2. Для распределения H_2 первые два начальных момента имеют вид:

$$M[X] = qt_1 + (1-q)t_2$$

$$M[X^2] = 2(qt_1^2 + (1-q)t_2^2)$$

В модели три параметра: q, t_1 и t_2. Поэтому по двум моментам сначала выбираем допустимое значение $q = 0,25$. Для исходных данных оно удовлетворяет условию:

$$q \le \frac{2}{1+\nu^2} = 0,517213$$

При $M[X] = 19,626160$ и $\nu = 1,693186$ средние фаз рассчитываются так:

$$t_1 = M[X]\left(1 + \sqrt{(1-q)\frac{\nu^2-1}{2q}}\right) = 52,468862$$

$$t_2 = M[X]\left(1 - \sqrt{\frac{q(\nu^2-1)}{2(1-q)}}\right) = 8,678593$$

Таким образом, первая фаза с вероятностью 0,25 описывает редкие большие значения, а вторая фаза с вероятностью 0,75 – преобладающие малые значения.

Реализация генератора гиперэкспоненциального распределения

Для формирования случайной последовательности реализована программа на Python. Для каждого нового значения генерируются два независимых равномерных псевдослучайных числа U_0 и U_1 из интервала $(0; 1)$. Первое число выбирает фазу гиперэкспоненциального распределения:

$$t = \begin{cases} t_1 & \text{при } U_0 < q \\ t_2 & \text{при } U_0 \geq q \end{cases}$$

После выбора фазы второе число преобразуется в экспоненциальную случайную величину методом обратного преобразования:

$$X = -t \ln(1 - U_1)$$

При $q = 0,25$ первая фаза со средним $t_1 = 52,468862$ выбирается с вероятностью 0,25, а вторая фаза со средним $t_2 = 8,678593$ – с вероятностью 0,75. Операция повторяется 300 раз, в результате формируется последовательность с выбранным законом распределения.

Для воспроизводимости результатов генератор инициализируется значением seed = 29: повторный запуск программы создаёт ту же последовательность.

```python
def run() -> None:

    parameters = fit_h2(load_values()) # парсим параметры

    values = generate_values(parameters) # генерим значения

    RESULTS_DIR.mkdir(parents=True, exist_ok=True) # сохраняем в папку

    header = f"seed={SEED}; q={parameters.q:.6f}; t1={parameters.t1:.6f}; t2={parameters.t2:.6f}"

    np.savetxt(RESULTS_DIR / "generated.txt", values, fmt="%.10f", header=header) # сохраняем в папку

    print(f"6. Сгенерировано {len(values)} значений с seed = {SEED}.")
```

```python
def generate_values(parameters: H2Parameters) -> np.ndarray:

    generator : Generator = np.random.default_rng(SEED) # задаем значения по сиду
    phase_numbers = generator.random(VALUES_COUNT)
    value_numbers = generator.random(VALUES_COUNT)

    # Первое число выбирает фазу, второе преобразуется в экспоненциальную величину
    phase_means = np.where(phase_numbers < parameters.q, parameters.t1, parameters.t2)
    return -phase_means * np.log1p(-value_numbers)
```

Рисунок 4. Алгоритм генерации гиперэкспоненциальной последовательности

Промежуточные выводы

Реализован генератор последовательности по выбранному аппроксимирующему закону. Сформировано 300 конечных неотрицательных значений в диапазоне от 0,040155 до 192,973406; расчёт их числовых характеристик автоматизирован.

Исследование сгенерированной последовательности

Для сгенерированной последовательности рассчитаны те же характеристики при объёмах 10, 20, 50, 100, 200 и 300, что и для исходной. Всё тоже самое, что и в начале вычислений:

Характеристика		10	20	50	100	200	300
Мат. ожидание	Знач.	12,205	16,044	20,963	20,309	18,293	18,873
	%	18,84	3,23	5,41	7,57	0,77	3,84
Дов. инт. 0,9	Знач.	±6,221	±9,717	±6,631	±4,400	±3,090	±2,782
	%	28,48	6,01	8,59	28,34	10,61	11,91
Дов. инт. 0,95	Знач.	±7,421	±11,591	±7,910	±5,249	±3,686	±3,318
	%	28,48	6,01	8,59	28,34	10,61	11,91
Дов. инт. 0,99	Знач.	±9,753	±15,235	±10,396	±6,898	±4,845	±4,361
	%	28,48	6,01	8,59	28,34	10,61	11,91
Дисперсия	Знач.	143,355	699,512	814,314	717,136	707,393	859,854
	%	48,85	11,66	16,45	48,65	20,09	22,39
С.к.о.	Знач.	11,973	26,448	28,536	26,779	26,597	29,323
	%	28,48	6,01	8,59	28,34	10,61	11,91
К-т вариации	Знач.	0,981	1,649	1,361	1,319	1,454	1,554
	%	11,87	2,88	13,29	22,47	11,29	8,39

Таблица 4. Характеристики сгенерированной числовой последовательности

Для полной выборки среднее равно 18,873, дисперсия - 859,854, СКО - 29,323, коэффициент вариации - 1,554. Отклонения от характеристик исходной последовательности составляют соответственно 3,84%, 22,39%, 11,91% и 8,39%.

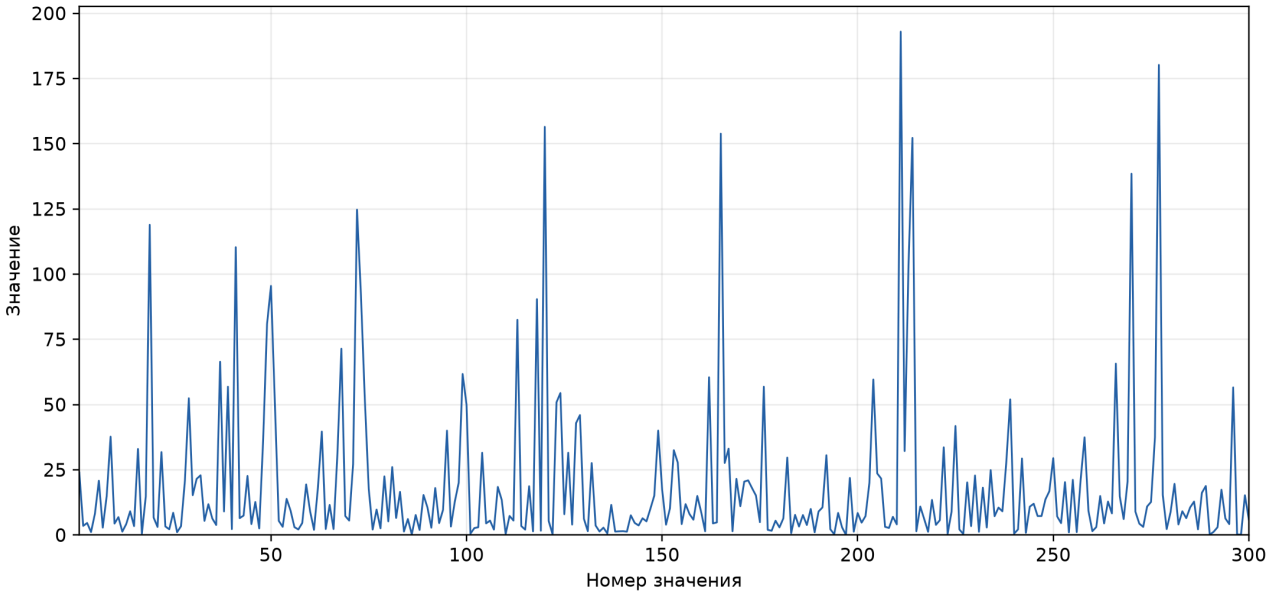


Рисунок 5. График значений сгенерированной ЧП

На графике отсутствуют выраженный рост, снижение и повторяющаяся структура. Малые значения преобладают и чередуются с редкими высокими пиками, как и в исходной последовательности.

Теоретическая плотность двухфазного гиперэкспоненциального закона имеет вид:

$$f(x) = \frac{q}{t_1}\exp\left(-\frac{x}{t_1}\right) + \frac{1-q}{t_2}\exp\left(-\frac{x}{t_2}\right), \quad x \geq 0$$

После подстановки найденных параметров получаем:

$$f(x) = 0,\frac{25}{52},468862\exp\left(-\frac{x}{52},468862\right) + 0,\frac{75}{8},678593\exp\left(-\frac{x}{8},678593\right)$$

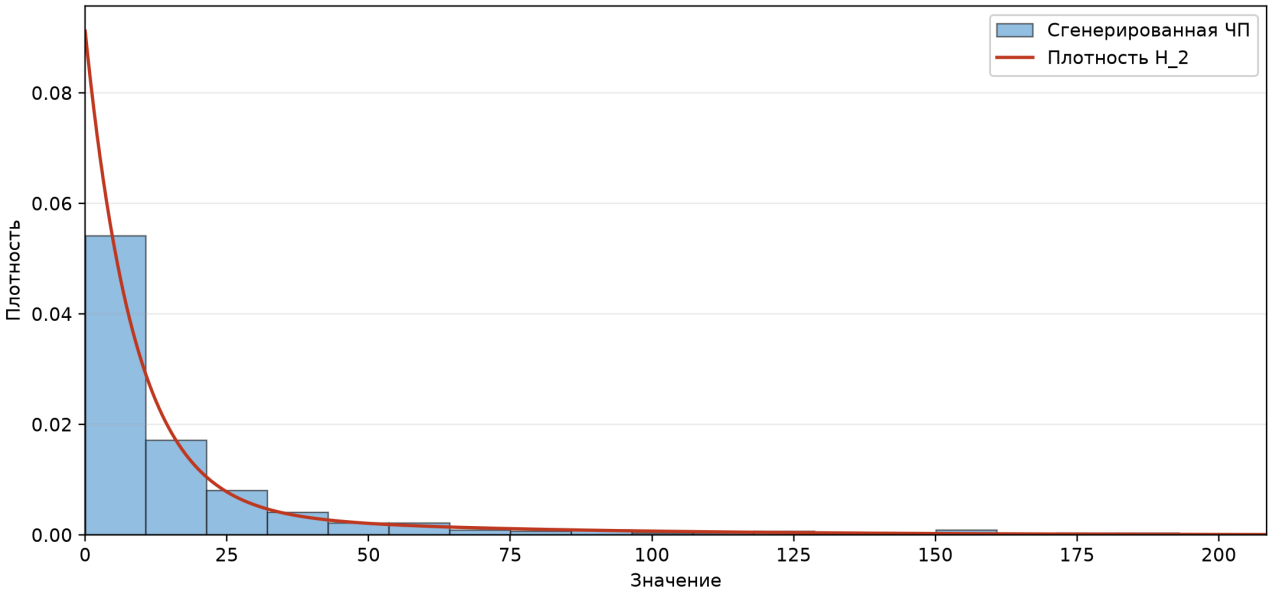


Рисунок 6. Гистограмма сгенерированной ЧП и теоретическая плотность H_2

Гистограмма согласуется с общей формой теоретической плотности: основная масса наблюдений сосредоточена у малых значений, после чего плотность быстро убывает и переходит в длинный правый хвост.

Коэффициенты автокорреляции сгенерированной последовательности:

Сдвиг ЧП	1	2	3	4	5	6	7	8	9	10
К-т АК	0,1014	0,0730	0,0702	−0,0183	−0,0141	−0,0534	0,0533	0,0090	0,0213	0,0035

Таблица 5. Автокорреляция сгенерированной ЧП

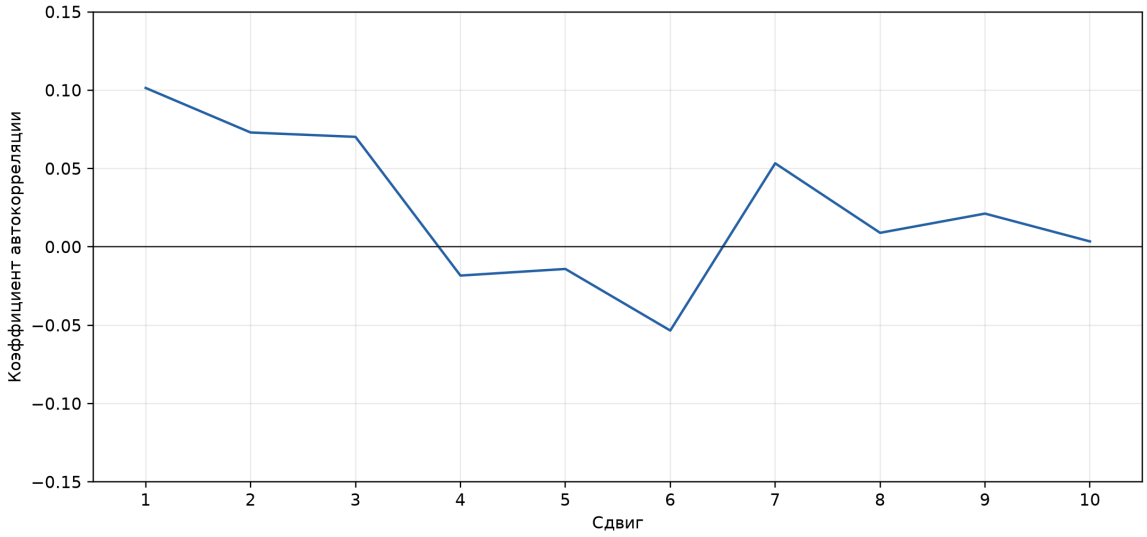


Рисунок 7. Автокорреляционный анализ сгенерированной ЧП

Промежуточные выводы

Максимальный по модулю коэффициент автокорреляции равен 0,1014 при сдвиге

1. Все коэффициенты находятся внутри ориентировочных границ $\pm 0,1132$, поэтому статистически заметная зависимость и признаки периодичности

не обнаружены. Сгенерированную последовательность можно считать случайной. По форме графика и гистограммы она воспроизводит основные особенности исходных данных.

Итоговое сравнение последовательностей

Результаты моделирования сопоставлены с исходной последовательностью по форме распределения, числовым характеристикам и автокорреляционной структуре.

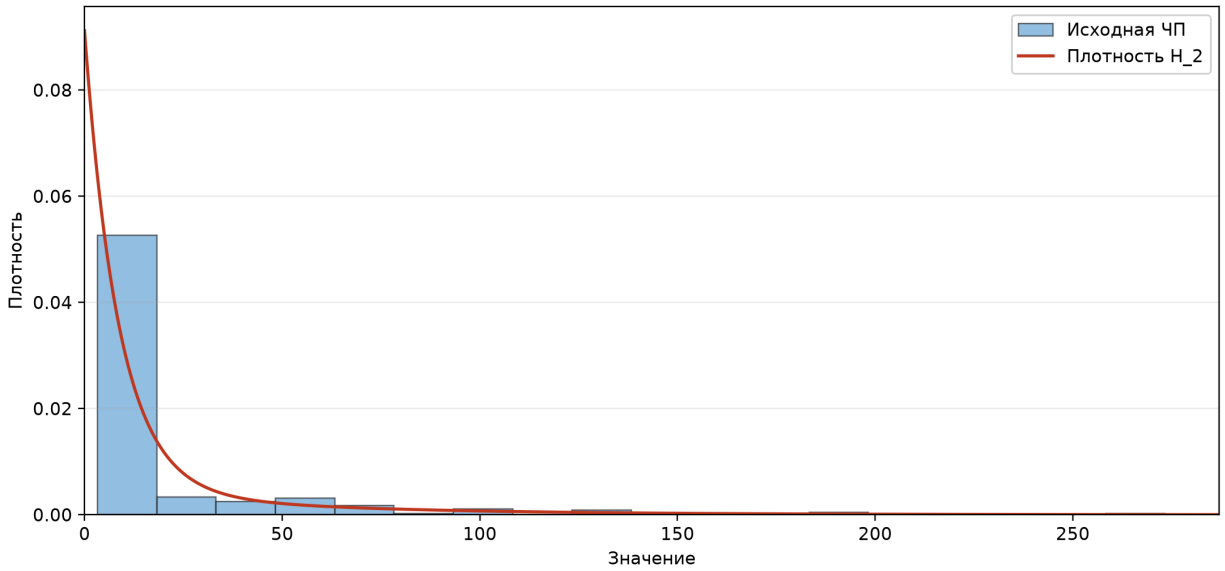


Рисунок 8. Гистограмма исходной ЧП и плотность распределения H_2

Точного совпадения высот отдельных столбцов ожидать не следует, поскольку гистограмма построена по конечной выборке.

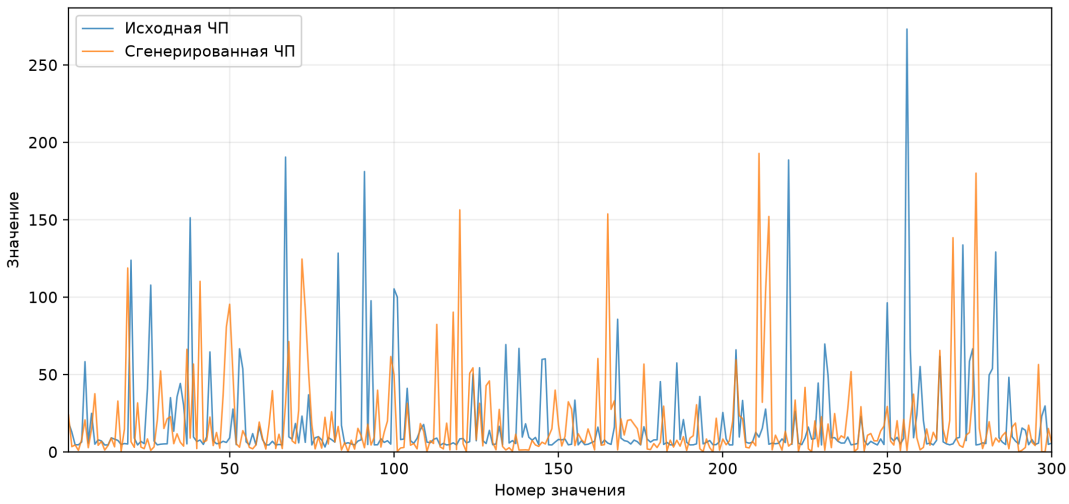


Рисунок 9. Сравнение реализаций исходной и сгенерированной ЧП

Последовательности имеют сходный масштаб и содержат редкие крупные значения. Совпадение элементов в одних и тех же позициях не требуется: модель должна воспроизводить вероятностные свойства исходной ЧП, а не её конкретную реализацию.

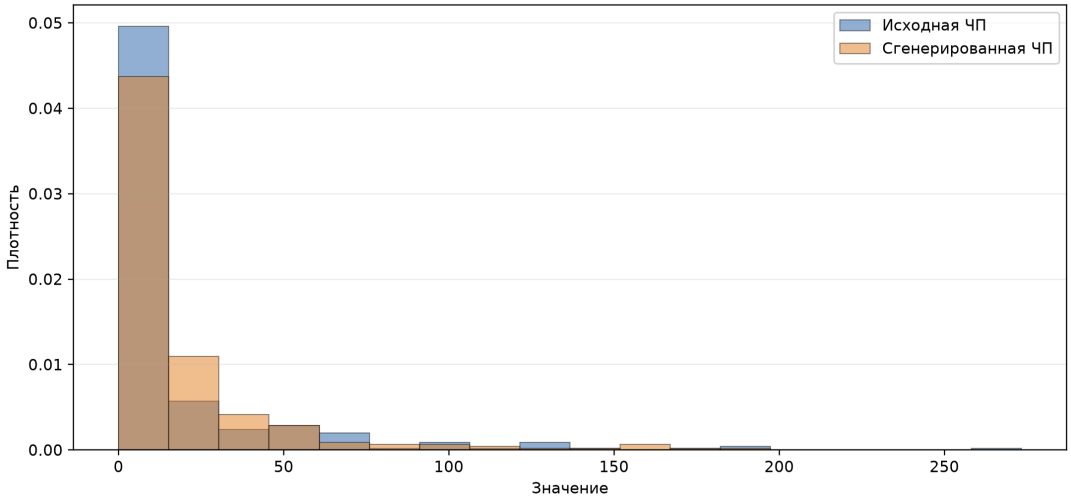


Рисунок 10. Сравнение нормированных гистограмм последовательностей

Обе гистограммы имеют выраженную асимметрию. Сгенерированная выборка несколько менее рассеяна, что согласуется с найденным отклонением дисперсии.

Результаты сравнения автокорреляционных коэффициентов представлены в форме 3. Относительное отклонение вычислялось по формуле

$$\delta_k = \left| \frac{r_k^{\text{ген}} - r_k^{\text{исх}}}{r_k^{\text{исх}}} \right| \cdot 100\%.$$

Сдвиг ЧП	1	2	3	4	5	6	7	8	9	10
Исходная	0,0169	−0,0064	−0,0610	−0,0580	−0,0760	0,0514	0,0120	0,0280	0,0269	0,0951
Сгенерированная	0,1014	0,0730	0,0702	−0,0183	−0,0141	−0,0534	0,0533	0,0090	0,0213	0,0035
Отклонение, %	500,83	-	215,16	68,45	81,49	203,88	345,58	67,97	21,00	96,33

Таблица 6. Форма 3 - сравнение результатов автокорреляционного анализа

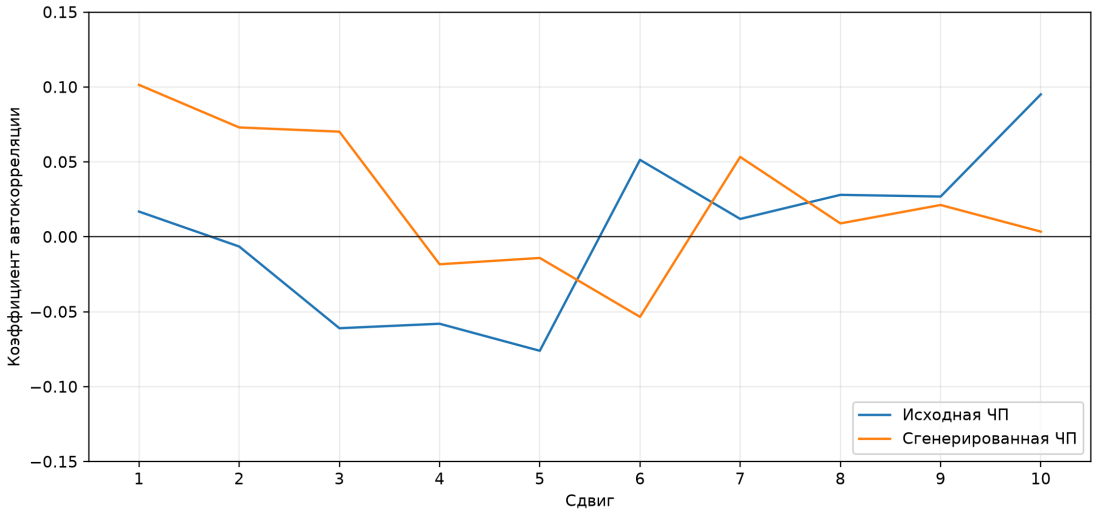


Рисунок 11. Сравнение автокорреляционных функций

Все коэффициенты обеих последовательностей находятся внутри доверительных границ $\pm 0,1132$, поэтому обе реализации можно предварительно считать случайными. Большие относительные отклонения в форме 3 вызваны делением на близкие к нулю исходные коэффициенты и сами по себе не означают сильной зависимости. Для сдвига 2 процент не указан, поскольку $|r_2^{\text{исх}}| < 0,01$.

Коэффициент корреляции:

$$r_{XY} = \frac{\text{cov}_{xy}}{\sigma_x \sigma_y} = \frac{\sum_{i=1}^{n} (x_i - M[X])(y_i - M[Y])}{\sqrt{\sum_{i=1}^{n} (x_i - M[X])^2 \sum_{i=1}^{n} (y_i - M[Y])^2}} = -0,050932.$$

Значение близко к нулю, что является ожидаемым результатом для независимо сгенерированной реализации.

Промежуточные выводы

Отклонение среднего составило 3,84%, дисперсии - 22,39%, среднего квадратического отклонения - 11,91%, коэффициента вариации - 8,39%. Модель хорошо воспроизводит среднее значение, правостороннюю форму распределения и случайный характер исходных данных. Отличие дисперсии объясняется конечным объёмом реализации и наличием редких больших значений; в целом качество моделирования можно считать удовлетворительным.

Вывод

Исходная числовая последовательность варианта 29 имеет математическое ожидание 19,626, дисперсию 1107,975, среднеквадратическое отклонение 33,286 и коэффициент вариации 1,696. Выраженный рост, снижение и периодичность не обнаружены. Коэффициенты автокорреляции для сдвигов 1-10 находятся внутри ориентировочных границ $\pm 0,1132$, поэтому последовательность можно предварительно считать случайной. Гистограмма имеет выраженную правостороннюю асимметрию и длинный правый хвост.

Поскольку коэффициент вариации больше единицы, для описания исходных данных выбрано двухфазное гиперэкспоненциальное распределение H_2. При $q = 0,25$ рассчитаны средние фаз $t_1 = 52,468862$ и $t_2 = 8,678593$. Полученная модель точно воспроизводит первые два эмпирических момента исходной последовательности.

Для сгенерированной последовательности отклонения среднего, дисперсии, СКО и коэффициента вариации составили соответственно 3,84%, 22,39%, 11,91% и 8,39%. Обе последовательности имеют сходную правостороннюю форму и не содержат значимой автокорреляции. Коэффициент корреляции Пирсона равен −0,050932, что ожидаемо для независимой реализации. Следовательно, модель H_2 удовлетворительно аппроксимирует основные вероятностные свойства исходной числовой последовательности.